

Naiba Chat 应用说明书 (2.3.5 Beta)

阅读路径

亮点速览 (用 30 秒了解 Naiba Chat 能干什么)

第 1 章 三分钟跑起来

- 1.1 它到底是什么
- 1.2 下载、解压、双击
- 1.3 第一次打开要做的四件事
- 1.4 界面 30 秒认识
- 1.5 你必须知道的三个开关
 - ① 审批档位
 - ② 深度思考
 - ③ 上下文提醒

第 2 章 一次对话能干什么

- 2.1 普通问答
- 2.2 让它读 / 写 / 搜文件
- 2.3 发附件给它
- 2.4 用 @ 引用工作区文件
- 2.5 让它看图、看 PDF
- 2.6 让它执行命令
- 2.7 让它发 HTTP 请求 / 联网搜
- 2.8 长任务放后台
- 2.9 中途插话、暂停、取消
- 2.10 上下文用量 & Token
- 2.11 本轮修改文件
- 2.12 右侧文件面板
- 2.13 编辑 / 重新生成 / 分支：三个「重开」入口

第 3 章 特色功能 (重点章)

- 3.1 每个会话单独选模型 (API 与模型分离)
- 3.2 长会话模式：聊一整天也不怕
- 30 秒试：手动划一条「新会话」分割线
- 能玩到什么程度
- 3.3 快捷消息：把常用提示词存成一键插入
- 3.4 一个不够就接一堆模型
- 3.5 Skill：给 AI 装“行业操作手册”
- 3.6 MCP：给 AI 插外设
- 3.7 ComfyUI 自动流水线
- 3.8 RunningHub 云端生成
- 3.9 并行与分身

3.10 手机/局域网远程访问 (功能对等)

- 3.11 权限与安全
- 3.12 稳如老狗
- 3.13 侧栏、收藏与折叠

第 4 章 场景实战

- 4.1 短剧/漫画批量出图
- 4.2 读懂并改造一个代码项目
- 4.3 批量整理资料 / 读 PDF
- 4.4 一句话跑一条流水线
- 4.5 用 Skill 把 AI 调教成领域专家

第 5 章 设置全解

- 5.1 API 供应商
- 5.2 Agent
- 5.3 运行设置
- 5.4 连接状态
- 5.5 视觉
- 5.6 联网搜索
- 5.7 Skills 管理
- 5.8 数据与迁移
- 5.9 软件更新
- 5.10 工作区

第 6 章 常见问题与高手技巧

- 6.1 模型连不上 / 报 500 / 代理冲突
- 6.2 ComfyUI 工作流报错
- 6.3 MCP 工具调不到
- 6.4 换了模型却不生效 / 图片发不出去
- 6.5 权限一直弹窗
- 6.6 上下文快满了怎么办
- 6.7 卡住了怎么办
- 6.8 高手技巧

附录

- A 文件都存哪儿
- B 速查卡
- 输入快捷键
- 消息上浮出的按钮
- 顶栏左侧下拉
- 顶栏按钮
- 底部状态栏
- C 术语表

Naiba Chat 应用说明书（2.3.5 Beta）

本说明书面向「第一次打开 Naiba Chat」的小白读者，配图全部来自真实运行界面（2.3.5 Beta · 源码模式 · 截图 2026-09-12）。

阅读路径

- 只想聊天 → 看第 1~2 章
- 想玩花的 → 重点看第 3 章
- 想查设置 → 直接翻第 5 章
- 出问题 → 第 6 章

亮点速览（用 30 秒了解 Naiba Chat 能干什么）

- AI 回复能「重新生成」，自己的消息能「编辑」**：鼠标移到任意一轮上——AI 回复右下角是「复制 · **重新生成** · 新会话」，自己的消息右下角是「**编辑** · 分支」。点「重新生成」就拿原来那句提问再答一次；点「编辑」则在原处就地改字重开，`/ref` 与 `@` 引用、这一轮的附件全都跟着走。
- 手机端功能对等 + 顶栏可折叠**：手机不再少半截——文件面板变**全屏抽屉**、「本轮修改的文件」恢复可点、桌面刻度轨换成顶栏「**轮次**」下拉，触摸目标统一 $\geq 44\text{px}$ ；顶栏还能一键收起，把被它占掉的高度还给会话区。
- Skill 删错了能救回来**：删 Skill 不再是「一点就没」——先弹确认框让你选「移到回收目录（可恢复）」还是「彻底删除」，设置页的回收目录里能一键恢复。
- 每个会话单独选模型**：顶栏选「API」（去哪儿），输入区选「模型」（派谁干），**按会话记忆、分支继承**，换完还自动重新探测图片能力；下拉末尾固定一个「**重新检测模型**」，供应商上新模型立刻可选。
- 长会话不会越聊越贵**：聊到上下文快满时划一条「新会话」分割线，线以上的老消息不再发给模型，**聊天记录一条不删**，还能让模型自己写交接文档再重置。
- 一个不够就接一堆模型**：OpenAI 兼容 / Anthropic / Gemini / Ollama / LM Studio / llama.cpp / Unsloth.....在线本地都能接。
- Skill：给 AI 装“行业操作手册”**：写小说、跑 ComfyUI、写视频提示词.....用 `/` 一键把领域知识塞进对话。
- MCP：给 AI 插外设**：ComfyUI、文件、网页.....只要 MCP 服务器在跑，AI 就能直接调用。
- ComfyUI 自动流水线**：批改工作流 → 批量提交 → 自动收图 → 缩略图预览 → 一句话复用到下一轮。
- RunningHub 云端生成**：没显卡也能出 420+ 类型的图、视频、音频、3D。
- 并行与分身**：后台 Job + 子 Agent，任务互不阻塞，跑图的时候还能写稿。
- 手机/局域网远程访问**：同 WiFi 打开链接，躺床上也能用家里电脑。
- 稳如老狗**：断线重连不重放、失败不丢已生成内容、5xx/429 自动重试、SHA-256 校验更新、可版本回退。
- 文件面板 + 本轮修改文件**：AI 改过的文件直接在右侧看、可编辑、可存回磁盘，**改了什么一目了然**。

第 1 章 三分钟跑起来

读完这章你能：自己装好 Naiba Chat、配上一个能跑的模型、发第一句对话。

1.1 它到底是什么

Naiba Chat 不是聊天框，是装在你电脑上的 **AI 工作台**——它能跟你对话，更能直接动手：读你的文件、改你的代码、跑你的命令、上网搜资料、出图出视频。**所有数据留在本地**，API Key 不出机器。

一句话比喻：**你雇了一个员工（Agent），给他配了工位（工作区）、工具箱（Tools）、行业手册（Skill）和外线电话（MCP），他干完活会把改过的文件摊在你桌上（文件面板）让你验收。**

1.2 下载、解压、双击


- 1. 去 GitHub Releases 页面下载 `naiba-chat-2.3.5-beta-windows-x64.zip`。
- 2. 解压到可写目录（桌面 / D 盘 / 工作盘都行，**不要放 C:\Program Files**，需要写权限）。
- 3. 双击 `naiba-chat.exe`（或源码模式直接 `python server.py`）。
- 4. 浏览器自动打开 `http://127.0.0.1:8765`，看到主界面就成功了。

从源码跑：`python -m pip install pywebview pystray pillow "mcp==2.1.1" pymupdf python-multipart`，然后 `python server.py`。

1.3 第一次打开要做的四件事

本机访问免口令；手机/局域网访问要口令（在「设置 → 连接状态」页查看）。

- 1. **添加一个 API** → 顶栏 ⚙ 设置 → 「API 供应商」→ 点「添加 API」卡片 → 填地址 / Key / 模型名 → 点「检查」测连通。



- 2. **选一个 Agent** → 顶栏「Agent」下拉里选一个（Agent = 人设 + 系统提示词 + 工具集）。


3. **选这个会话要用的模型** → 顶栏「API」下拉选刚才加的连接，**输入框下方左边「模型」下拉**（列表就是该 API 的模型目录）选一个。



4. **发第一句话** → 底部输入框打字 → 按 **Enter** 或点 ↑ 发送。

没配过模型？ 主界面空态里已经放了常用指令卡片（点一下就发），新手按顺序点「列出可用工具」试试水。

主界面长这样：



1.4 界面 30 秒认识

区域	你能干什么
顶栏左	展开/收起侧栏（状态会记住）
顶栏中	切 API（连接配置）、切 Agent（两个下拉）
顶栏右	文件 / 任务 / Skill / MCP 状态 / 刷新
左侧栏	工作区分组、会话列表、底部「已收藏」分组
中间聊天区	对话、思考块、工具块、产物、本轮修改文件、 新会话分割线
聊天区右侧	对话刻度轨 ：一轮一条横条，点一下跳到那一轮
右侧文件面板	AI 改过的文件在这里多标签预览/编辑
底部输入区	附件列表 / 添加文件 / 思考强度 / 上下文圆环 / 发送
底部状态栏	模型下拉 （本会话用哪个模型）、工作区下拉、 审批按钮 （点开是三档上拉框）、快捷消息 右侧：思考强度、上下文百分比、就绪状态

1.5 你必须知道的三个开关


① 审批档位

底部左侧的「**审批**」按钮，决定 AI 跑工具要不要你点头。**收起时它只是一个按钮**（显示当前档位，风险越高颜色越醒目），**点一下**才在按钮上方弹出三档列表：



- **确认**（默认）：每次工具调用都弹「需要确认」卡片 → 你点「允许执行」才跑（**最安全**）。
- **自动**：工作区内自动放行；工作区外（**读也算**）仍会停下弹确认卡。
- **完全**：不再询问，可访问工作区外（**最省事，但写错可能毁文件**）。


选完、切换会话、打开别的浮层、按 **Esc**、点外面，列表都会收起。工作区外写操作时会停下弹确认卡：



已经没有「轻量 / 富文本」开关了——**AI 能用哪些工具完全由 Agent 的工具集决定**，不再有会话级开关。想收窄能力，去「设置 → Agent」里改工具集。

这个控件从「平铺四段」改成了上拉框，省出的横向空间留给工作区和模型选择器；窄屏也不会被挤变形。

② 深度思考




输入区右侧的球形按钮，点开有 5 档：

- **跟随 API（自动）**——按模型自身行为
- **关闭**——直接答，不思考
- **低 / 中 / 高**——强制思考强度

当前档位常显在输入框下方（「思考 自动」）。模型支持时（DeepSeek-R1、Claude、o 系列）才有效，否则忽略。

注意：点这个按钮**只展开/收起列表**，不会再顺手帮你切档。

③ 上下文提醒



输入框右侧的彩色圆环 + 下方常驻的「上下文 x.x%」就是上下文用量：


- 每次模型请求后刷新，70% 转黄、90% 转红，鼠标悬停看 已用 / 上限 。
- 超过阈值（默认 80%，在「设置 → 运行设置」改，填 0 关闭）会弹窗提醒，建议让模型写交接文档并开始新会话。
- 隔 5 个百分点才提醒第二次，不会一直弹。

第 2 章 一次对话能干什么

读完这章你能：让 AI 读你的文件、改你的代码、跑你的命令、出你的图，而且知道每一步在背后发生了什么。

2.1 普通问答

直接在输入框打字发就行。AI 拿到的是你**当前会话的上下文**（Agent 系统提示词 + 历史消息 + Skill + 工具结果）。一条典型的「思考 → 工具 → 正文」交错长这样：




2.2 让它读 / 写 / 搜文件

你说的话	AI 用什么
「读一下 README.md 头三行」	<code>read_file</code>
「把 build_info.json 的 version 改成新版本号」	<code>read_file</code> + <code>edit_file</code>
「在 docs/ 下搜包含 'TODO' 的 md」	<code>search_files</code>
「列出工作区所有 png」	<code>list_directory</code>
「在 assets/ 下创建 cover.jpg 占位」	<code>write_file</code>
「把这两个文件合成一个」	<code>read_file</code> + <code>write_file</code>

所有写操作默认是「工作区内允许、工作区外询问」（取决于审批档位）。

2.3 发附件给它


拖文件进输入框、粘贴、或点左侧回形针都能加附件。待发送附件在输入框上方竖排显示：一行一个，图片有缩略图，每行右侧 × 可单独移除。



- **纯附件也能发**：输入框一个字不写，直接点发送。模型会明确收到「用户未输入文字，只发送了以下附件」+ 附件路径，不会自己脑补你的诉求。
- 上传是流式直传，有真实进度，单文件可取消，多文件最多 3 个并行，单文件上限 80MB。
- 重复文件自动去重，移除未发送的附件会自动清理文件。

2.4 用 @ 引用工作区文件

输入空格 + @ 就弹出当前工作区的目录列表：




- **↑↓ 选择、Tab 进入子目录、Shift+Tab 返回上级、Enter 或点击即引用。**
- 手机没 Tab 键：点目录行右侧的 > 箭头进入，列表首项「返回上一级」逐级退出。
- 引用后输入框里保留 @相对路径 高亮，**发送时自动替换成绝对路径**；目录保留尾部的 /，模型就知道要处理整个目录。
- 只有工作区里真实存在的路径才会被替换，所以 @gmail.com 这种普通文本不受影响。

2.5 让它看图、看 PDF

- **直接拖图片到输入框** → 自动作为本轮附件。
- **让它看自己之前生成的图** → 用缩略图右下角 ↺ 复用按钮发回输入框。
- **多图分批**：vision_analyze 单批 4 张，超出的自动分批并标注「共 N 张 / 已展示前 M 张」，模型不会误以为只有这几张。
- **PDF 三件套**：read_pdf 抽文本层、pdf_render_pages 把页面渲成图、pdf_zoom_region 局部高清放大看小字和表格。扫描件（没文本层）会自动引导转页图，再让视觉模型识图。

视觉后端在「设置 → 视觉」里挑供应商，留空会走免费兜底链：



文本模型收到图片时只拿到路径引用，由模型按需调用 `vision_analyze`（结果以工具块呈现）；原生多模态模型直接收到原图。


2.6 让它执行命令

Naiba Chat 只用一个工具：`pwsh`（PowerShell 7+）。所有系统操作都走它。

"在 `D:\naiba-chat` 下跑 `pytest`，失败的话把 `trace` 给我看"

2.7 让它发 HTTP 请求 / 联网搜


- `http_request`：GET/POST/PUT/DELETE 都行，可设 header / body / 超时。
- `web_search`：需在「设置 → 联网搜索」配置 API profile。搜索结果会作为「联网来源」折叠块附在消息末尾，当素材引用，别当真理。



2.8 长任务放后台

对耗时任务（出图、出视频、跑大命令）AI 会自动用 `run_in_background` 启动后台 Job，按 `job_output` 轮询。

顶栏「任务」按钮随时能看所有后台任务的历史和状态：



`run_in_background` / `job_output` / `job_status` / `job_wait` / `job_kill` 五个工具覆盖完整生命周期。

后台跑着也能继续聊天：以前只要有一个长跑或卡住的异步任务，这个会话再发消息就会被拒掉（界面显示「当前对话已有 Run，已恢复其进度」，消息其实没入队）。现在**只有顶层对话本身占住互斥位**，后台 Job 不再阻塞下一轮——跑图的时候照样能接着问它有别的事。


任务面板的「停止」是真能停：点它会真正中止运行中的任务（不再只是个摆样子 disabled 的按钮）。顶层的对话仍走原来的「暂停 / 取消」。

重启不会把任务越搞越多：以前每重启一次，中断的任务就被再恢复一遍（ $1 \rightarrow 2 \rightarrow 4 \rightarrow 8$ 成倍增长），实测能把一批 8 段生成放大成每对话 13 份。现在恢复后会给源任务打上持久标记，重复副本只保留最新一条、其余标记为已接续；你主动点的 `retry` / `resume` 不受影响。

2.9 中途插话、暂停、取消

- **插话：**AI 跑着时，你在输入框打字回车 → AI 接住你这条引导，把当前步骤合并（用于纠偏）。
- **暂停：**消息下面的「暂停」按钮 → 停止当前轮，**已生成内容保留**。
- **取消：**右上角 × → 标记当前轮为「中止」，已生成内容同样保留。
- **停止级联子任务：**取消父任务会自动 kill 所有子任务。


2.10 上下文用量 & Token



- **彩色环**（输入区右）：上下文用满的百分比，越满越红。
- **点开查看详情**：本轮消耗（输入 / 输出 / 缓存命中率 / 请求数 / 生成速率）。
- **缓存命中率**：70% 以上是常态；突然掉到 0% 说明切了模型或改了系统提示词，DeepSeek 等支持前缀缓存的模型会贵一点。

2.11 本轮修改文件


每轮结束后，AI 用 `write_file` / `edit_file` 改过的文件会在消息末尾列出来：



- **新** = 新建，**改** = 编辑。
- **多媒体产物**（图片 / 视频 / 音频）走原附件卡片，**不进 chip**（避免重复）。
- **点文件名** → 右侧文件面板打开（见 2.12）。
- **中止/失败的轮次**只要写盘成功也保留记录。

2.12 右侧文件面板


点 chip 或顶栏「文件」按钮 → 右侧文件面板打开，多标签管理：



文件类型	行为
Markdown	直接渲染（带表格 / 代码块）
文本（.py / .json / .txt 等）	可手动编辑 → <code>Ctrl/⌘+S</code> 或 <code>Ctrl/⌘+Enter</code> 保存回磁盘， <code>Esc</code> 取消
图片	直接预览，点开是大图
PDF / 二进制	走 PDF 三件套或给出明确提示，不再吐乱码

安全边界：面板只允许看**本会话改动过**或**位于会话工作区内**的文件，「保存写回」要求同时满足两者。路径越界一律拒绝（不能当任意文件读写入口用）。

面板左缘可以拖动调宽（280px ~ 半个窗口，会记住）。收起后顶栏出现「文件」按钮，标签都还在：



2.13 编辑 / 重新生成 / 分支：三个「重开」入口

鼠标移到任意一轮消息上，右下角会浮出一行小按钮。它们的共同点是**回到那个时间点重来一次**，所以先记住一条原则：**这一轮之后的消息会被删掉，之前的全部保留。**



按钮	出现在	干什么
编辑	自己的消息	在那条消息的位置就地展开编辑框，改完按同一条提问重发
分支	自己的消息	从这条消息分叉到一个 新会话 ，旧会话原样不动
复制	AI 回复	复制整条回复
重新生成	AI 回复	拿这条回复对应的那句提问 原样再答一次 （一个字都不用改）
新会话	AI 回复	在这里划一条分割线，线以上的老消息不再发给模型（见 3.2）

为什么反复点「重新生成」不会越点越乱

截断点落在**那条提问**上，而不是这条 AI 回复上。后果是：

- 它前面几轮的问答**逐字节不动**，DeepSeek 这类支持前缀缓存的模型继续命中缓存（省的就是这笔钱）；
- 反复点同一个按钮，被重发的始终是同一句提问，**不会像「从回复处截断」那样越点越积出一串重复提问**。

点完会提示「正在重新生成（复用前缀缓存）」；「编辑」成功后提示「已从该消息重开，编辑点之前的上下文将复用缓存」。

「重新生成」什么时候弹确认框

- **后面已经没有消息、输入框里也没草稿**：直接重跑，不打断你。
- **后面还有消息**：弹确认框，并写明「这条回复之后还有 N 条消息，会一并删除」。
- **输入框里有草稿**：同样会提醒「输入框里的草稿会被替换成这条提问」。

⚠ 截断不可逆：确认之后，那一轮之后的对话就真的删掉了。万一这一轮重发出错，删掉的部分不会自己长回来——所以不确定时，先用「分支」留一条退路。

改字时这些东西不会丢

- **引用**：编辑框里回填的是你当初输入的原样文本，`/ref` 技能引用和 `@` 工作区引用**一字不改**地跟着走。`@` 仍然在发送那一刻按这个会话的工作区替换成绝对路径，所以重发结果和第一次完全一致。
- **附件**：这一轮原来发的图片 / 文件会原样带回。**纯附件轮次**（只丢了个文件、一个字没写）也能重发，不会再被「内容不能为空」拦下来。

编辑态下，底部输入区整体让位

在会话里点「编辑」后，编辑框就长在那条消息上；底部输入框会锁住并显示：

正在编辑上面的消息：在编辑框里 Ctrl+Enter 确认，Esc 取消

同时底部发送键变成「**重新发送**」，可用性跟着编辑框里的字数走（清空就禁用），待发送的附件列表也暂时收起——免得你「以为在编辑旧消息，其实在写新消息」。

- `Ctrl+Enter`、或点编辑框里的「重新发送」= 确认这条路重开；
- `Esc`、或点「取消」= 放弃这次编辑，原文原样还在。

已知边界：编辑态下**不能增删附件**，只能原样重发那一轮的附件。要换附件就别走「编辑」，直接开一轮新的。

会话正在回答的时候，「编辑」和「重新生成」会自动隐藏（和「分支」「新会话」一个口径），避免跟进行中的回复打架。这时候硬要用，会提示「请先等待当前回答结束或停止」。

「**分支**」出来的是**新会话**，会继承同一个 API 和模型名，分过去不用重新选模型。

第 3 章 特色功能（重点章）

读完这章你能：把 Naiba Chat 调成你顺手的样子，知道哪些功能可以替你省 1 小时/天。

每节固定结构：**痛点** → **30 秒试** → **能玩到什么程度** → **注意**。

3.1 每个会话单独选模型（API 与模型分离）

痛点：以前顶栏「模型」下拉里塞的是「API 名称 · 模型名」的拼串——切一下既换供应商又换模型，同一个会话里想只换模型（比如从便宜的换到强的）就得去设置里改；而且换完模型，图片能力还是按上一个模型记的，容易误判。

30 秒试

1. 看**顶栏**：现在叫「**API**」，只负责选连接配置（哪个供应商、哪个地址、哪个 Key），选项直接显示 API 名称。
2. 看**输入框下方最左边**：新增「**模型**」下拉，打开会话时会自动拉取当前 API 的模型目录，选一个就**存到这个会话**。
3. 下拉里只有**当前 API 实际检测到的模型**，没有手写框——免得你填了一个目录里压根不存在的名字，发出去才报错。
4. 供应商后来上架了新模型？下拉末尾固定有一项「**重新检测模型**」，选它就当场重拉一次目录，**刷新前的选择会自动还原**，不必再进设置页点「检查模型」。它只是一次动作、不是模型选项，不会被写进会话、也不会发给服务端。



能玩到什么程度

- **按会话记忆**：新建会话、继续会话都按**这个会话自己选的模型**发送。A 会话用 DeepSeek 写稿、B 会话用本地模型跑批，互不干扰。
- **分支继承**：从某条消息「分支」出来的新会话，会继承同一个 API 和模型名。
- **切 API 会清空模型名**：顶栏换 API 后，模型名一并清空让你重新选（不同供应商的模型名不一样，留着没意义），**也不会再偷偷回退到配置里的那个默认模型**。
- **没选过就不替你选**：会话还没明确选过模型时，下拉显示禁用占位项「**请选择模型...**」，要你自己挑一次——以前会默认选中目录里的第一项，而那个顺序只是供应商接口的返回顺序，没有任何含义，等于悄悄替你决定了对答的模型。
- **目录里没有但以前选过**：旧会话保存的模型名如果不在当前目录里，会置顶显示成「**已保存：xxx（请重新检查模型）**」提醒你，但不会替你选中它。
- **目录拿不到就直说**：拉取失败时下拉是空的、占位显示「请先在设置中检查模型」，发送也会被拦下来。**不再静默回退到 API 配置里的默认模型**——宁可不发，也不发到一个你没验证过的模型名上。
- **空目录算「还没查到」**：有些 API 在还没加载好时会返回空列表；以前空结果也算「查过了」，这一页就再也不重试，下拉永久卡住。现在改成**缓存里确实有模型才复用**，空了会自动重拉。
- **重拉失败会出声**：拿不到目录提示「无法获取模型目录：具体原因」，还没配 API 提示先去设置页，目录确实为空提示「该 API 当前没有可用模型」。
- **自动重新探测图像能力**：换 API 或换模型名后，`chat_supports_images` 重置为「待探测」，发送时按新模型的**真实能力**判断——换到纯文本模型不会再误发图片，换到多模态模型也不会再被当成纯文本。
- API 供应商卡片也瘦身了：只保留两行（名称 + 格式标签），模型名不再上卡片。

注意


- **顶栏 = 选「去哪儿」（连接），输入区 = 选「派谁干」（模型），这两个是两个独立开关。**
- 升级会自动完成数据库迁移（给 `conversations` 表加 `model_name` 列），幂等、不会重复执行。
- 切了会话但模型串了多半是切太快：已修掉「目录返回时会话已切换」导致旧会话模型串到新会话的问题。
- **以前没主动选过模型的会话（含老会话），需要你在下拉里显式选一次才能发送**——这是有意为之，不替你把钱花到没挑过的模型上。

3.2 长会话模式：聊一整天也不怕

痛点：长对话越聊越长，token 越来越贵；而且前面跑题的几十轮一直在占用上下文，真正有用的进展被淹没了。开新会话吧，前面聊的又全丢了。

30 秒试：手动划一条「新会话」分割线

在任意一条 AI 回复的右下角点「**新会话**」（操作区三个按钮：复制·重新生成·新会话），就会在那条回复下面画出一条分割线：



这条线以上的消息不再进入模型上下文，这条线以下的消息仍在上下文里——所以你只裁掉前面跑题的部分、保留最近的进展就行。聊天记录一条不删，随时点「撤销」把线撤掉。

能玩到什么程度

- **多条分割线并存：**靠时间和位置区分，最新那条决定当前上下文起点。
- **模型也能自己重置：**在 Agent 工具集里勾上 `reset_context` 后，模型可以先把交接文档写进工作区、再调用它——**文档不存在或为空会被拒绝**，每轮最多成功一次。成功后本轮立即收尾，在该条回复下画出「模型重置」分割线。
- **种子消息自动填进输入框：**模型重置后，输入框会自动填好「交接文档路径 + 请先读取再继续 + 仍在运行的后台任务清单」，你确认后点发送就开始新一段。模板可以在「设置 → 运行设置 → 新会话种子消息」里改（占位符 `{handoff_path}` / `{task_count}` / `{task_list}`）。
- **交接文档快捷键：**快捷消息面板里内置了「写交接报告并 `reset_context`」预设，点一下插进输入框就行（见 3.3）。
- **翻历史不靠翻页：**Agent 工具集里新增「长会话」一组——
 - `find_conversations`：按标题列出最近会话（id / 标题 / 时间 / 条数 / 末条预览）
 - `recall_history`：按关键词检索（不给会话 id 就全库搜、每个会话最多 3 条片段；给了 id 就只搜那个会话）
 - `read_conversation`：按序号区间读历史会话原文，用来复核片段

- `reset_context`：重置上下文

直接问 AI「上个月我们聊过的那版分镜脚本在哪」即可。检索结果会明示「检索了全部 N 个会话 / M 条消息」，**当前会话的命中会标注「在上下文中」或「已划出上下文」**——被分割线划出去的老消息不会被当成你还记得的内容。 - 「长会话模式」预设：Agent 工具集预设里直接选，等于标准模式 + 这四件套。 - **长会话懒加载**：打开会话只渲染最近 10 轮，向上滚动自动往前补（每次 10 轮，视口不跳动），几万条历史也不卡。 - **对话刻度轨**：聊天区右侧一列横条，一轮一条，滚动时视口所在轮次会加粗凸起，悬停看概要（第 N 轮 + 用户消息一行 + 回复两行），点一下跳过去。长会话只显示附近 30 条，窄屏自动隐藏。


注意

- 分割线**只影响发给模型的内容**，不影响你看到的聊天记录。
- 划了线之后如果又想让模型参考上面的内容，点「撤销」即可，或者用 `recall_history` 把片段捞回来。
- 模型自己调 `reset_context` 前**必须先写出交接文档**，否则会被拒绝——这是故意的，防止上下文凭空消失。

3.3 快捷消息：把常用提示词存成一键插入

痛点：有些话你一天要说十遍（「按老规矩整理一下」「写交接报告然后重置」），每次手打很烦。

30 秒试：输入框下方点「快捷消息」→ 点列表里任意一条 → 正文直接进输入框（还能改）→ 发送。



能玩到什么程度

- **每条只有正文、不用起标题**：列表拿正文首行当标题，其余折叠成预览。
- **自动排序**：按「使用次数 × 2 + 新鲜度加分」排，常用的稳定靠前，新加的 7/30/90 天内有曝光窗口不会永远沉底。
- 行内 编辑、 删除、 新建 添加（弹窗里只填正文）。


- **内置交接报告预设**（带「默认」标签）：点一下就要求模型把交接报告写进工作区，再用 `read_file` 复核后调 `reset_context`。它跟你自建的条目**同权**——可以编辑、可以删除，软件更新不会覆盖也不会复活。

注意：这是**独立列表**，跟开始页的自定义指令卡片互不影响，各自增删改。

3.4 一个不够就接一堆模型

痛点：单一模型又慢又贵还偏科。能不能 A 写代码 / B 写文案 / C 出图？

30 秒试：设置 → API 供应商 → 点「添加 API」→ 选请求格式 → 填地址 / Key / 模型名 → 点「检查」秒测连通。



能玩到什么程度

- **在线：**OpenAI 兼容（OpenAI / DeepSeek / Grok 等）、Anthropic、Gemini。
- **本地：**LM Studio / Ollama / llama.cpp / Unsloth，本地模型卸载在「设置 → API 供应商」里操作。
- 每个供应商独立设置温度、上下文长度、最大输出。
- **卡片化：**供应商和 Agent 都改成卡片网格，点卡片才弹设置表单，右上角 × 删除。
- **5xx 自动重试：**供应商返回 500/502 这类瞬时故障时自动退避重试（1.5s / 3s，最多 3 次），状态栏会提示重试进度，不再直接终止整轮。


注意

- **怎么切模型：**先顶栏「API」选连接，再在输入框下方「模型」下拉选具体模型（见 3.1 节）。
- 切换模型不影响会话历史，但会**重新探测图像能力**——换到纯文本模型后图片就不会再被发出去。
- **切 Agent 会改首条消息固化下来的工具集**（首轮注入，之后不可改）。

3.5 Skill：给 AI 装"行业操作手册"

痛点：通用 AI 不懂你的行业术语、不熟你常用的 workflow。

30 秒试：输入 / 弹窗 → 选一个 Skill (比如 cangjie 拆书) → 直接对话「把这段小说拆成 12 集」。




能玩到什么程度

- ↑↓ 选、Enter 确认。
- **首轮注入** system / **后续轮追加到末尾**，保持 DeepSeek 前缀缓存稳定。
- 安装 Skill 支持 .zip / .md / 整个文件夹：



- 隐藏 / 恢复在「设置 → Skills 管理」：



- **删错了也能救回来**：点删除会先弹确认框，让你在「移到回收目录（可恢复）」和「彻底删除」之间二选一，并列这个 Skill 被哪些 Agent 引用着（删除会一并移除引用）。回收掉的东西不会消失，而是落到设置页面里那个「回收目录」区块，点一下就恢复；同页还有「已隐藏 Skill」列表兜住另一种情况。真要不留痕迹，再点「清空回收目录」——那时才是永久删除。

重要概念

Skill 只是说明书，不是开关。 缺 Skill 时，已授权的通用 Tool / MCP 仍可用；Skill 只指导调用方式，**不注册服务、不扩展权限。**

Skill 脚本规范：脚本统一放 Skill 目录的 `scripts/` 子目录，读写文件要显式写 `encoding='utf-8'`。

安装目录归属（修了一个狠的数据事故）：以前导入单个 `.md` 或顶层散放 `SKILL.md` 的 zip，定义文件会直接落在托管 Skills 目录的根上，**删这一个 Skill 会把整个目录搬走、所有 Skill 一起消失。**现在凡是直接落在导入根的上传都会先建独立子目录，删除前也会校验归属（越界一律拒绝）；升级时会自动把历史裸文件迁入同名子目录，引用不会断。


删 Skill 的三条退路：① 普通删除是「移到回收目录」，设置页 Skills 管理下方能一键恢复；② 同一个 Skill 在好几处目录都有一份时（比如打包内置 + 托管副本），只搬走一份它会立刻从另一份复活——现在这类按 ID 统一隐藏，一次点掉即从列表消失且重启不回来，可在「已隐藏 Skill」里恢复；③ 「彻底删除」是把文件直接删掉，**不可恢复**，选之前会再问一次。

单文件不用再补 frontmatter：单个 `.md`、或 zip 里顶层散放的 `SKILL.md`，没有 YAML frontmatter 也能装了——自动取第一个标题当名称、第一段正文当说明，正文原样保留。

3.6 MCP：给 AI 插外设

痛点：AI 不能直接调 ComfyUI、数据库、第三方 API。

30 秒试：装好 MCP 服务器（比如 `npx -y @comfyorg/comfy-mcp`）→ 设置 → 连接状态里看到它就绪 → 直接对话「用 comfy 出 6 张封面」。



能玩到什么程度

- 启动时自动连接已启用的服务，没连上的做周期重试。
- 顶栏 MCP 圆点看状态：**绿=已连接、红=未连接/出错、黄=连接中、灰=未配置**，悬停看详情。

- 手机/局域网访问地址 + 访问口令也在这一页。

注意（最常见踩坑）

新加的 MCP 必须重开会话才生效。 改完 MCP 配置 → 关掉当前会话 → 重新开 → MCP 工具才进可用集。

3.7 ComfyUI 自动流水线

痛点：跑 ComfyUI workflow 要切窗口、改参数、收图、改名、传图.....繁琐。

30 秒试（前提：装好 ComfyUI + comfy-mcp）：

"用当前目录下的 `cover_v2.json` 出 12 张 1080x1440 封面，seed 1-12"

能玩到什么程度

- 批改本地 workflow 再引用路径**，别把大 JSON 贴进对话：用 `read_file` / `comfyui_prepare_workflow` 读，用 `edit_file` 局部改，再用 `comfyui_batch` 的 `workflow_paths` 提交文件路径。
- 产物自动落到 `data/generated`，聊天里直接预览、点开大图、↩ 复用。
- 后台任务完成后产物**自动挂回发起它的那条消息**，不用再追问模型。
- 视频/音频可以在气泡里直接播放（支持拖动进度条）。
- ComfyUI 弄丢镜头会自动补救**：如果你重启了 ComfyUI 或清了队列，已提交的镜头会从 `/history` 和 `/queue` 里同时消失。以前程序把「查不到」当成「还在跑」，一路空转到超时（默认两小时），任务面板长期挂着「运行中 · 完成 5/8」不动；现在每轮会核对一次队列，确认被丢弃的镜头按预算（`max_resubmit`，默认 1）自动重新提交同一 workflow 接着跑，预算用尽则记为「ComfyUI 已丢失该任务」并正常收尾，不再无限空转。

注意

- UI JSON ≠ API JSON**：UI 拖拽的连线图直接保存不能喂 API，导出时要选「API 格式」。
- ComfyUI 自身**不传图**给模型，AI 看的是产物缩略图（必要时调视觉模型）。


3.8 RunningHub 云端生成

痛点：本地没显卡，ComfyUI 跑不动。

30 秒试：装 `runninghub` Skill → 对话「用 runninghub 的文生图出 6 张古风封面」。

能玩到什么程度

- 不用显卡，420+ 端点：文生图、图生视频、TTS、音乐、3D、图片放大、跑任意 AI 应用。
- 产物在聊天里直接以缩略图网格预览，每张右下角 ↩ 一键发回输入框复用：



- 切换站点（国内 / 海外）在「设置 → Skills 管理」里。

注意：需要你自己的 RunningHub 账号和额度。

3.9 并行与分身

- **后台 Job：** `run_in_background` 跑长任务，不阻塞主对话。
- **子 Agent：** `subagent` 工具起一个独立 Agent 干另一件事，结束后回报。

适用：一边跑图、一边写文档；一边跑分析、一边查资料。

3.10 手机/局域网远程访问（功能对等）

痛点：在沙发上不想开电脑，但想让家里的 Naiba Chat 跑点啥——而且不想因为用手机就少一堆功能。

30 秒试：设置 → 连接状态 → 复制带口令和 IP 的链接 → 同一 WiFi 的手机浏览器打开。



设置页在手机上同样完整可用：

设置

模型与运行参数



API 供应商

Agent

运行设置

连接状态

视觉

聊

在线 API

本地 API

mimo



OpenAI 兼容

TE CODEX



Codex /responses

GG公益



OpenAI 兼容

当前

deepseek



OpenAI 兼容

teds



OpenAI 兼容

teds



OpenAI 兼容

摆烂白嫖



OpenAI 兼容

摆烂ds



能玩到什么程度（「功能对等」）

原则只有一句：不删能力，只换形态。电脑上有的，手机上都有；放不下的控件换成等价的样子。

桌面	手机上换成
右侧文件面板	全屏抽屉 （占满屏幕打开，看完关掉；和桌面共用同一套开合逻辑）
消息末尾「本轮修改的文件」	恢复可点 ，点一下直接打开文件抽屉
聊天区右侧「对话刻度轨」	顶栏 「轮次」下拉 ：列出「第 N 轮 · 用户消息摘要」，选中即跳过去，滚动时自动显示当前轮次（不足 2 轮自动隐藏）
鼠标悬停/点击	触摸目标统一 ≥44px （顶栏按钮、侧栏开关、输入区图标与发送、文件面板关闭）
——	顶栏可一键收起 ：收起后整条操作区让位，API 与 Agent 两个下拉并回第一行

手机上点文件名，文件面板就以全屏抽屉打开：

build_html.py

文本 · 10.4 KB · D:\naiba-chat\docs\manual\build_html.py

```
"""README.md → docs/manual/index.html（带左侧目录、阅读样
式、图片灯箱）。"""
import re
import html as html_mod
from pathlib import Path
import markdown

ROOT = Path(__file__).resolve().parent
MD_PATH = ROOT / 'README.md'
HTML_PATH = ROOT / 'index.html'
IMG_DIR = ROOT / 'images'

md_text = MD_PATH.read_text(encoding='utf-8')

# 版本号一律从 README 标题派生，避免「改了 md 忘了改这里」——
# 历史上有过 PDF 名还停在旧版本的情况。
_m = re.search(r'^#\s+.*?(\d+\.\d+\.\d+)\s+Beta)',
md_text, re.M)
VERSION = _m.group(1) if _m else '0.0.0'
PDF_NAME = f'Naiba-Chat-手册-{VERSION}.pdf'
TITLE = f'Naiba Chat 应用说明书 · {VERSION} Beta'

# 把 19/20/21 引用补进文档末尾占位
placeholder = '''<!--
待补配图（涉及真实会话内容，需授权或自行补充）：
- 示例对话截图 1：流式渲染（思考块 + 工具块 + 正文交错）
- 示例对话截图 2：产物卡片（图片/视频缩略图 + 预览 + 下载）
- 示例对话截图 3：工具审批确认弹窗
建议命名：19-chat-streaming.png / 20-chat-artifacts.png
/ 21-tool-approval.png
→'''
if '19-chat-streaming.png' not in md_text:
    md_text = md_text.replace(placeholder, '').rstrip()
+ '\n'

# === 渲染 ===
md = markdown.Markdown(extensions=['extra', 'toc',
'sane_lists', 'tables'], output_format='html5')
body_html = md.convert(md_text)

# 优先用 webp（已转码时大幅瘦身）；若 webp 不存在则保留 png
from pathlib import Path as P
```

顶栏收起：把屏幕还给会话区

手机上顶栏要挤下轮次、文件、任务、Skill、MCP、刷新这一串按钮，小屏很吃亏。现在它右上角多了个开关：



GG公益



通用 Agent



手机上也给手机放个聊天气体吧？

- **收起后**隐藏整条操作区（轮次 / 文件 / 任务 / Skill / MCP / 刷新临时让位），**API 与 Agent 两个下拉并回第一行**，屏幕高度全部还给会话区。
- 想用那些按钮时，点一下它下面那条细箭头就回来。
- 这个选择**记在本地**，刷新后还在；桌面端根本不渲染这个按钮。
- 跨过 760px 边界（比如旋转屏幕、接外接屏）**不会顺手把文件面板关掉**。
- 窄屏也不隐藏任何文字标签，宁可整行换行，不会出现「一个问号图标猜它是啥」。
- 手机判定只有一个来源（CSS 760px 断点），不会出现「同一台设备有时像手机有时像电脑」。


注意：外网访问需要内网穿透；本机访问免口令，**局域网访问必须口令**。

3.11 权限与安全


- 对话、设置、附件、任务状态**全部存本地**，不出你的机器。
- 文件预览只允许工作区和受管理数据目录（`data/uploads`、`data/generated`）。
- **API Key 不出机器**——所有在线模型调用都从你的电脑直接发到供应商，不经中转。
- 高风险写入、删除、外部发布和凭据操作仍受权限策略保护。
- **缓存管理：**图片/PDF/视频/音频统一统计，设置页打开即刷新；超限自动清理（默认 256MB，可调，填 0 关闭）**只删未被消息引用的最旧文件**——历史消息引用的附件永不会自动删除。

3.12 稳如老狗

- **断线重连**不重复回放：网络抖一下，不会把同一段响应重发两次。
- **失败不丢已生成内容：**模型报错，已经写出的思考/部分回复/工具活动完整保留。
- **出错自动重试：**HTTP 5xx（含 500）与 429/502/503/504 同等对待，按 1.5s / 3s 退避重试、最多 3 次；失败请求体会落盘到 `naiba-model-error-payload.json` 取证（超长字段截断、**不含 API Key**）。
- **Codex Responses 聚合回填：**只收到「事件汇总」没有逐字流也能正确拿到正文、思考和工具调用，不会被误判成空答复；这种格式下真出现空流会按瞬时故障重发。
- **停止级联子任务：**父任务停 → 子任务全部 kill。
- **更新带 SHA-256 校验：**下载完先校哈希再替换，损坏直接拒绝。
- **可版本回退：**更新面板支持「选历史版本 → 一键回退」。



3.13 侧栏、收藏与折叠



- **折叠**：桌面端点侧栏顶部 ◀ 收起（列宽恒定 880px，只是重新居中），聊天区左上 ▶ 展开，**状态会记住**。移动端左上角 三 滑出抽屉。

- **收藏**：会话条目的**五角星**点一下即收藏；侧栏底部有跨工作区的「已收藏」分组。收藏**同时保留在原工作区**，两处都显示，而且**不会把会话顶到列表最前**。
- ... **菜单**：重命名和删除收在这里；新建工作区也是对话框（选目录 → 填名称）。
- 条目整条可点，点击时列表不会强制滚到最上（已可见就保持位置）。

第 4 章 场景实战

读完这章你能：把第 3 章的能力翻译成「我今天就用的场景」。

4.1 短剧/漫画批量出图

两条路：

- **本地 ComfyUI**（你有显卡）→ 3.7 节
- **云端 RunningHub**（没显卡）→ 3.8 节

通用流程

1. 工作区建好，参考图、风格参考放进去。
2. 提示词模板放 Skill 里（参考 `h3-prompt-writing`）。
3. AI 改本地工作流（标记哪些是占位参数）→ 批改 → 提交。
4. 产物自动进 `data/generated`，缩略图在聊天里。
5. 看效果，AI 继续改 prompt，再批跑。

可直接复制的提示词

「用当前工作区的 `cover_v2.json` 出 12 张 1080x1440 古风竖构图封面，seed 1-12，人物参考用 `reference_sheet.png`。用完用「本轮修改」列表给我看哪些参数改过。」

4.2 读懂并改造一个代码项目

"读 `D:\my-project` 下 `main.py` 和 `requirements.txt`，告诉我这个项目在做什么、依赖什么、入口在哪。然后把 `main.py` 里的硬编码路径改成支持环境变量。"

AI 会先 `read_file` → `search_files` 查引用 → `edit_file` 改 → 文件面板里你能直接看并改回。

4.3 批量整理资料 / 读 PDF

"把 `D:\桌面\inbox` 下所有 `pdf` 按年月重命名（`YYYYMM_原名.pdf`），建个 `README.md` 列出改名清单。"

适合：下载文件夹归类、扫描件整理、合同/发票归档。扫描件（没文本层）AI 会自动转页图再用视觉模型认字。

4.4 一句话跑一条流水线

"读 E:\reports 下的 50 份 csv，统计每个用户的总消费，按消费降序输出到 E:\reports\summary.csv，前 10 名加颜色标红。"

AI 自己拆步骤：列文件 → 读 → 聚合 → 写。

4.5 用 Skill 把 AI 调教成领域专家


- **cangjie**：拆小说 → 短剧分集
- **h3-prompt-writing / h3-text-to-promptv2**：把剧情写成 MiniMax H3 视频提示词
- **comfyui-shortdrama**：ComfyUI 短剧工作流专精
- **shortdramav2-rh**：RunningHub 上的短剧工作流

用 / 引用 Skill 后，AI 输出的就是该领域的标准格式，不用每次都交代。

第 5 章 设置全解

每个 tab 一节，按页面顺序排。

5.1 API 供应商




- **卡片网格**：一行最多三张，末尾固定「添加 API」卡片，卡片右上角 × 删除；点卡片才弹设置表单。
- **请求格式**：OpenAI 兼容 / Anthropic / Gemini / Ollama / LM Studio / llama.cpp / Unsloth 等。
- **「检查」按钮**：测连通 + 测图片能力 + 测工具调用。
- **温度 / 上下文 / 最大输出**：每个供应商独立。
- **API Key 留空 = 保留原值**（不用每次重填）。


「API」和「模型」是两个独立开关：这一页配的是**连接**（去哪儿）。具体用哪个模型，在**输入框下方左边的「模型」**下拉里选（列表来自该 API 的模型目录），按会话记忆。详见 3.1 节。

卡片很紧凑：每张卡片压成两行——名称 + 格式标签（当前使用的有角标），模型名不再上卡片，卡片高度从 116px 降到 88px。


5.2 Agent



- **卡片网格**：末尾固定「新增 Agent」卡片。卡片上显示固定 Skill 数和它**当前用的工具集名称**（「工具集：标准模式」/「未限制（全部工具）」/「自定义 · N 个工具」）。
- **不再标「默认」角标**——默认项由顶栏 Agent 选择器体现。
- **点卡片进编辑表单**：




- **ID 自动生成**：新建不用填 ID，保存时后台分配；已有 ID 显示在副标题。
- **自定义头像**：上传图片自动中心裁切为 256px WebP；用了这个 Agent 的会话，助手气泡的「AI」圆标会换成这张头像。
- **系统提示词（预设与规则）**：标题行右侧就是工具栏——套用快捷提示词 / 存为快捷提示词 / 导入角色卡 PNG / 自定义头像。角色卡是追加语义，不覆盖你手写的内容。
- **工具集两态**：默认显示 4 张只读预设卡（只读 / 标准 / ComfyUI 联动 / 全能）+ 「我的工具集」+ 虚线「添加自定义工具集」；点任意一张，工具列表从下方滑入，命名栏自动填上卡片名字，勾选就是该卡的工具，可继续增删再存成「我的工具集」。**内置预设只读，自定义可删。**



重要规则：工具集在首条消息固化，之后不可改。要换工具集就开新会话。


「我的工具集」存在后端 `config.json`（不再存 `localStorage`），重启不会丢。想做长会话的话，工具集预设里直接选「**长会话模式**」（标准 + `find_conversations` / `recall_history` / `read_conversation` / `reset_context`）。

5.3 运行设置




- **命令超时**（只管工具/命令，不管模型响应）
- **上下文提醒阈值**（默认 80%，填 0 关闭）
- **新会话种子消息模板**（ {handoff_path} / {task_count} / {task_list} ）
- **原图上传**（关闭则压缩后传）、**上传最大像素 / 缩略图尺寸 / 缓存清理阈值**

5.4 连接状态




上半：MCP 列表（绿点已连接 / 红点出错 / 灰点未启用）。下半：手机访问地址 + 访问口令 + 局域网 URL。

5.5 视觉




- **视觉供应商**：留空 = 走免费兜底链
- **单次视觉请求超时 (毫秒)**
- **最大图片数**：单轮占位引用的图片数上限（默认 4）

5.6 联网搜索




- 搜索 API profile（可配多个）
- 搜索结果当素材引用，**别当真理**


5.7 Skills 管理



- 已装 Skill 列表 + 启用/隐藏切换 + 恢复已隐藏。
- 装新 Skill → 点「安装 Skill」按钮或拖 .zip / .md。
- RunningHub 站点切换也在这里。




5.8 数据与迁移



- 数据库版本 / 数据目录 / 当前 Skills 目录 / 健康状态 / 备份位置。


- **历史数据管理**：查看数据库占用并一键压缩回收空间（实测 400MB 可压到 ~90MB，继续会话发给模型的历史消息逐字节不变）。
- 「备份」一键压缩 `data/` 到 `backups/`，**升级前必做**。

5.9 软件更新



- **EXE 模式**：自动检查 → 下载 → SHA-256 校验 → 提示重启。
- **源码模式**：**不支持一键更新**，需 `git pull --ff-only` 然后重启服务。
- 目标版本下拉可选历史版本 + 回退；检查完成后自动选中新版本。

5.10 工作区



- 工作区 = AI 可读写的根目录（安全边界）。
- 在输入框下方的「工作区」下拉或设置页添加，支持直接选目录 / 浏览 / 上级跳转。
- **切换分组即切换目录**：把会话移到某个工作区分组，其磁盘工作区同步指向该分组目录；「移至未分组」只改侧栏分类、保留原目录。

第 6 章 常见问题与高手技巧

6.1 模型连不上 / 报 500 / 代理冲突

- 「检查」按钮能告诉你**网络层 vs API Key vs 路径**是哪一层错。
- 国内访问海外供应商常需开系统代理；Naiba Chat 不内置代理，但遇到代理进程重启导致的连接拒绝会自动改用直连重试。
- **5xx 会自动重试**（1.5s / 3s，最多 3 次）；如果三次都失败，去看进程工作目录下的 `naiba-model-error-payload.json`（不含 API Key）。
- DeepSeek 触发速率限制的话，**等 60 秒**再试。

6.2 ComfyUI 工作流报错

- **UI JSON ≠ API JSON**：导出时**必须**选「API 格式」。
- 报错 `Prompt outputs failed validation`：节点连线断了，重开 UI 检查。

- comfy-mcp 圆点红色：见 3.6 节。

6.3 MCP 工具调不到

新加的 MCP 必须重开会话才生效。配完 → 关当前会话 → 重新开。

6.4 换了模型却不生效 / 图片发不出去

- **确认两处都选了**：顶栏「API」是连接，输入框下方「模型」才是真正干活的那一个，两个都要对。
- **下拉停在「请选择模型...」或发不出去**：这是现在的有意行为——会话没有明确选过模型时不替你选，必须你在下拉里挑一个。挑完就能发。
- **下拉停在「请先在设置中检查模型」**：当前 API 的模型目录没拉到（Key 不对、地址不通、供应商没开通这个模型），去「设置 → API 供应商」点「检查模型」。
- **新上架的模型列表里没有**：下拉末尾选一次「 重新检测模型」当场重拉；别去设置页绕一圈。
- **显示「已保存：xxx（请重新检查模型）」**：这个会话以前存过的模型已经不在目录里了（供应商下线或改名）。先「检查模型」拿到目录，再重新选一个。
- **换了模型仍按旧能力走**：切 API 或换模型名会自动把图像能力重置为「待探测」，下一次发送按新模型的真实能力判断；如果还是不对，重开一次会话让它重新探测。
- **想让 A 会话用便宜模型、B 会话用强模型**：直接在各自的会话里选就行，模型名按会话记忆，互不干扰。

6.5 权限一直弹窗

- 先看档位：切到「**自动**」= 工作区内免问，工作区外（读也算）仍会问；「**完全**」= 不再询问，可访问工作区外（**慎用**）。
- **工作区里的文件也要问？** 看确认卡上写的「当前工作区：...」——那是判定用的目录。如果这个会话切换过工作区，以前会出现「判定按新工作区、实际读写按启动时的旧工作区」，导致工作区内的文件被判越界反复弹窗；现在判定与执行统一按**当前会话的工作区**，已经修掉了。
- 子 Agent 报「无法确定工作区目录」：同样属于这类问题，现已改为继承**当前会话**的工作区与审批档位（权限不会超出父级）。
- **还是搞不清为什么被判越界**：设环境变量 `NAIBA_DEBUG_PERMISSION=1` 后重启，每次权限判定都会写日志（执行器身份、请求的原始与解析后路径、当前工作区、允许根、命中结果），照着一查就知道。
- 工作区里指向外部的链接（junction / 符号链接）**按真实目标判定**，仍然算越界。

6.6 上下文快满了怎么办

1. 看输入框下方「上下文 x%」——70% 黄、90% 红。
2. 到 80% 会弹窗提醒，选「让模型写交接文档 + 开始新会话」。
3. 或者手动点某条回复下面的「**新会话**」划分割线。
4. 想更省：勾上 `reset_context` 工具，让模型自己判断何时重置。

6.7 卡住了怎么办

1. 消息下方「暂停」按钮。

- 2. 看「任务」面板有没有跑死的后台任务 → 杀掉。
- 3. 看上下文用量环是不是满了 → 划分割线或开新会话。
- 4. 实在不行重开会话（**会话内容会保留**）。

6.8 高手技巧

- 1. **↑↓ 选 Skill / @ 引文件用 Tab 进目录 / Enter 发送 / Shift+Enter 换行。**
- 2. **运行中 Enter 插话**（引导合并到当前轮）。
- 3. **Ctrl+Enter 全部引导**（取消当前轮 + 把引导作为新轮发）。
- 4. **纯附件就能发**：不写字直接点发送，模型会收到明确说明，不会瞎猜。
- 5. **消息分支**（点自己消息「分支」按钮）→ 新会话接着干。
- 6. **Token 环判断缓存命中**：掉到 0% 提示「可能改了系统提示词」。
- 7. **快捷消息**：把一天说十遍的话存进去，点一下就进输入框。
- 8. **数据目录备份再升级**：设置 → 数据与迁移 → 备份。
- 9. **历史太大就压缩**：设置 → 数据与迁移 → 历史数据管理 → 压缩。
- 10. **手机扫码直连**：设置 → 连接状态里复制带口令的局域网地址。
- 11. **按会话换模型**：A 会话用便宜模型跑批、B 会话用强模型写稿，各自在输入框下方「模型」下拉里选，互不干扰。

附录

A 文件都存哪儿

D:\naibachatdata\	← 数据根目录（冻结版固定 %LOCALAPPDATA%\NaibaChat）
├─ config.json	← 主配置（含 Agent / 工具集 / 快捷消息）
├─ conversations.db	← 会话数据库
├─ uploads\	← 你上传的附件（按日分目录）
├─ generated\	← AI 生成的产物（缩略图 + 原图）
├─ <conversation-id>\	
├─ image_00000.webp	← 原图
├─ image_00000_thumb.webp	← 缩略图
└─ video_00000.mp4	
├─ avatars\	← Agent 自定义头像（256px WebP）
├─ skill_history\	← Skill 引用历史
├─ backups\	← 备份（ zip ）
└─ logs\	← 运行日志
D:\naiba-chat\	← 项目根（可改）
├─ skills\	← 装在本项目的 Skill
D:\skills\	← 用户级 Skill （可选）

B 速查卡

输入快捷键

按键	作用
/	弹 Skill 列表
/skill-name	引用指定 Skill
@	弹工作区文件/目录列表（ Tab 进目录、 Shift+Tab 返回）
↑↓ + Enter	在弹层里选择
Enter	发送消息
Shift+Enter	换行
Ctrl+Enter	确认编辑（在消息上的编辑框里）
Esc	关闭弹窗 / 取消编辑 / 关文件面板

消息上浮出的按钮

位置	按钮	作用
自己的消息	编辑	在原处改字后重发（引用与附件都带着走）
自己的消息	分支	从这一条分叉到新会话（继承同一 API 与模型）
AI 回复	复制	复制整条回复
AI 回复	重新生成	用那条提问原样再答一次（前面的上下文一字不动）
AI 回复	新会话	在此划分割线，线以上不再进模型上下文

顶栏左侧下拉

下拉	作用
API	选连接配置（哪个供应商 / 地址 / Key）， 切换后该会话的模型名清空重选
Agent	选人设 + 系统提示词 + 工具集（首条消息后工具集固化）

顶栏按钮

按钮	作用
文件	重新打开文件面板（保留已打开的标签）
N 任务	看所有后台 Job（可在这里 停止 运行中的任务）
N Skill	看当前会话已选的 Skill
MCP	圆点看连接状态（绿/红/黄/灰）
刷新	整页 reload（内嵌窗口用不了 F5 时点它）
收起/展开顶栏	仅手机端（≤760px）有：收起整条操作区，把屏幕还给会话区

底部状态栏

控件	默认	说明
模型	未选（显示「请选择模型...」）	本会话用哪个模型；列表来自当前 API 的检测目录，必须显式选一次才能发送；末尾「🔄重新检测模型」可当场重拉目录
工作区	未分组	AI 能读写的目录根 = 安全边界
审批（按钮）	确认	点开是上拉框，三档：确认 / 自动 / 完全（完全慎用）
快捷消息		常用提示词一键插入
思考 自动	✓	当前思考强度（点输入区球形按钮切）
上下文 --		实时百分比，70% 黄 / 90% 红

C 术语表

术语	一句话 + 比喻
Agent	人设 + 系统提示词 + 工具集。 比喻 ：员工岗。
Skill	给 Agent 的"行业培训手册"。 比喻 ：岗位操作手册。
MCP	Agent 能调用的外部服务接口。 比喻 ：员工桌上的电话。
Tool	Naiba Chat 内置的能力（读文件、跑命令等）。 比喻 ：员工的手。
工具集	一个 Agent 被允许使用的工具清单。 比喻 ：上岗时发的工具箱。
Job	后台跑着的任务。 比喻 ：员工出去跑外勤。
API（连接）	一个供应商的地址 + Key 配置。 比喻 ：你要打哪条外线。
模型	具体干活的那个 AI 大脑，按会话选。 比喻 ：这一单派哪位专家。
托管 Skills 目录	Skill 的安装根，每个 Skill 一个子目录。 比喻 ：书架上的一格放一本。
工作区	AI 能读写的目录根，安全边界。 比喻 ：员工能进的办公室。
审批档	AI 跑工具要不要你点头的开关。 比喻 ：出门要不要老板签字。
新会话分割线	在此线以上截断上下文、不删聊天记录。 比喻 ：给笔记本换一页，旧页还在。
交接文档	重置前让 AI 写的工作小结。 比喻 ：换班交接单。
刻度轨	聊天区右侧的一轮一条横条。 比喻 ：书页侧边的章节标签。
本轮修改文件	一轮对话里 AI 写盘的所有文件。 比喻 ：本轮会议纪要。
文件面板	右侧多标签的文件预览/编辑器。 比喻 ：桌上摊开的文件。
缓存命中率	DeepSeek 等模型前缀缓存的命中比例。 比喻 ：省钱的程度。
上下文固化	Agent 工具集在首条消息固定。 比喻 ：上岗后不能改工种。

版本：2.3.5 Beta · 截图 2026-09-12 项目仓库：<https://github.com/yc883123/naiba-chat> 反馈：<https://github.com/yc883123/naiba-chat/issues>